

品牌 Category 发现与 AI 验证

样例结果与方法说明

Yunxiang Mo · 2026 年 10 月

摘要

我从 Kantar BrandZ 2025 世界和中国品牌价值榜各前 100 名出发，建立了 **60 个消费品类、共 957 行**的 Category → Brand 表，并用固定问题 “*What are the best brands for {category}? List 10 brands.*” 逐一验证每个品类名称。

- 补全品牌表并为 5 个品类改名后，用 DeepSeek V4 Pro 验证，**60 个品类全部通过** (Brand Recall@10 ≥ 0.8)。
- 部分品牌是看过 DeepSeek 回答后才补进的，因此我冻结品牌表，又做了两项**独立检验**：
 - DeepSeek 在 temperature 1.0 下重新采样：**44/60** 通过。
 - 换用 Qwen 3.7 Plus：**32/60** 通过，另有 12 类得 0.7，只差 1 个品牌。
 - 两项检验都通过的有 **28 类**。
- 所有报告轮次的 API 总花费约 **0.34 美元**。

方法

Task 1：品牌 → 品类。 种子池为 Kantar BrandZ 2025 全球最具价值品牌前 100 名与中国最具价值品牌前 100 名，去重后共 189 个 (World 88、China 101)。每个品牌归入一个主品类，并合并同义标签 (30 次合并)，得到 66 个品类。其中 6 个 B2B 品类 (如半导体、企业软件) 保留归类但不做验证，因为本项目面向消费者搜索。**未归类种子品牌数为 0。**

Task 2：扩充品牌。 对 60 个消费品类，逐类从公开榜单页面 (Wikipedia 列表、Brand Finance、行业统计等) 补充其他主要品牌，每一行都附来源链接。**每个品类均有 10 个以上品牌** (最少 10，中位数 16，最多 29)。World/China 按总部所在地划分：中国大陆、香港、澳门记为 China。

Task 3：AI 验证。 通过 OpenRouter 对每个品类单独提问一次 (全新单轮请求)。把回答解析成品牌列表，按下式计分：

Brand Recall@10 = AI 给出的前 10 个品牌中出现在该品类品牌表里的个数 ÷ 10，≥ 0.8 记为通过。

品牌名先做规范化，处理大小写、重音、标点和 Inc./Group/.com 等后缀；再用别名表合并同一品牌的不同写法，例如 Shoo Loong Kan = 小龙坎。AI 返回不足 10 个时，缺的位置算作未命中。

某个品类未通过时，我会逐一查看 AI 返回了哪些不在表里的品牌，并判断失败原因：

- 品牌表缺失：** AI 给出的是该品类的真实品牌，只是表里没有。只有当独立来源 (主要是 Wikipedia 摘要) 明确说明它属于该品类时才补入；135 个候选中采纳了 119 个。补入的行都做了标记，报告中始终同时给出不含这些行的”补表前” recall。
- 品类名被误解：** AI 回答的是另一个品类。这种情况就改名重测，共 5 例，见下表。

结果

轮次	模型 / temperature	品牌表口径	通过	平均 Recall@10
第 1 轮 (首次打分)	DeepSeek V4 Pro / 0	初始表	23 / 60	0.63
第 1 轮	DeepSeek V4 Pro / 0	初始表 (补表前)	26 / 60	0.69
第 1 轮	DeepSeek V4 Pro / 0	补表后	56 / 60	0.88
第 2 轮 (5 个改名品类)	DeepSeek V4 Pro / 0	补表后	5 / 5	0.96
最终 (每类最近一次尝试)	DeepSeek V4 Pro / 0	补表后	60 / 60	—
留出检验 (冻结表)	DeepSeek V4 Pro / 1.0	补表后	44 / 60	0.80
跨模型检验 (冻结表)	Qwen 3.7 Plus / 0	补表后	32 / 60	0.72
跨模型检验 (冻结表)	Qwen 3.7 Plus / 0	补表前	20 / 60	0.62

列定义。轮次：对各品类完整跑一遍。第一行使用的是最初的解析器和别名表，后来已修复，例如它曾把 Markdown 子弹点里的说明文字当成品牌。这一行保留用于透明说明，其余各行都是用最终代码对同一批已保存的回答重新打分。品牌表口径：“补表前”不含验证后补入的 119 个品牌。通过：Recall@10 ≥ 0.8 的品类数。平均 Recall@10：各品类的平均值，取值 0–1。每轮每个品类只采样一次，未计算置信区间。

改名的品类（第 1 轮 → 第 2 轮，DeepSeek）：

原名称	AI 的表现	新名称	改名后 Recall@10
Real Estate Developers	列出家电/装修品牌（Sub-Zero、Miele）	Chinese Real Estate Developers	0.9
Credit Card Networks	混入发卡行（Chase、Capital One）	Payment Card Networks	0.9
Home Improvement Stores	列出工具/油漆品牌（DeWalt、Benjamin Moore）	Home Improvement Retail Chains	1.0
Cigarettes	拒绝回答	Cigarette Brands	1.0
AI Chatbots	列出公司名（OpenAI、Anthropic）	AI Chatbot Apps	1.0

列定义。AI 的表现：我对第 1 轮回答的概括。改名后 Recall@10：第 2 轮补表后的得分。AI Chatbots 单靠改名没有用，回答仍是公司名；它是在加了“公司 → 产品”的映射（如 OpenAI → ChatGPT）后才通过的，这个映射是我的人工判断。

主表样例（完整主表 957 行，见附件）：

Category	Brand	World/China	验证结果
Smartphones	Apple / Samsung / Google Pixel	World	Pass
Smartphones	Xiaomi / Huawei / OPPO / vivo	China	Pass
Baijiu	Moutai / Wuliangye / Luzhou Laojiao	China	Pass
Electric Vehicles	Tesla / BMW	World	Pass
Electric Vehicles	BYD / Li Auto / NIO	China	Pass
Bubble Tea Chains	Mixue Bingcheng / Heytea / Chagee	China	Pass

列定义。正式主表每行一个品牌，这里为节省篇幅，每行合并列出几个。验证结果：该品类最近一次尝试的结果。

检验说明了什么

- 观察：补入的品牌在新的回答上同样有效。DeepSeek 留出检验中，通过数从补表前的 29 升到 44；Qwen 从 20 升到 32。说明补表不是只迎合了某一次回答，但 60/60 偏乐观。
- 观察：两个模型在 40/60 个品类上结论一致：28 类都通过，12 类都不通过。都不通过的包括：宽泛的食品饮料类（Dairy Products、Beer、Energy Drinks、Processed Meat Products、Hot Pot Restaurant Chains），服务类（Insurance Companies、Hotel Chains、Supermarket Chains、Online Healthcare Platforms），以及 Cosmetics、Drones、Traditional Chinese Medicine。
- 观察（Qwen）：Qwen 把“Online Shopping Platforms”理解成电商建站软件（Shopify、WooCommerce），recall 为 0.0；把“AI Chatbot Apps”部分理解成企业客服机器人工具（Intercom、ManyChat）。这类命名问题只用一个模型发现不了。
- 解读：其余未命中的大多是表外的真实品牌，包括美国区域或小众品牌（Mint Mobile、USAA、GEICO）、高端或精酿类（Aman、Westmalle），以及直营美妆（Rare Beauty）。品类名越宽，AI 每次给出的长尾品牌越不一样，改用更窄的名称（按子品类或市场）可能更稳定。这一点尚未验证。

局限

- 每轮每个品类只采样一次，没有计算方差或置信区间。
- 补表和部分别名是在看过第 1 轮回答之后加的。对此，报告给出了补表前的 recall，并用冻结表做了留出检验和跨模型检验作为对照。

- Task 2 中约一半的行依据的是搜索结果摘要，而不是完整网页。World/China 标签以及“明确属于该品类”都是人工判断。
- 两个验证模型的回答都偏美国市场，会影响 World/China 的平衡。

扩展到 1000 个品类的下一步

1. 扩大种子池：加入 Kantar 和 Brand Finance 的分行业榜单，以及电商类目树。
2. 半自动化 Task 2：从多个来源生成候选品牌，再人工抽检。
3. 默认多模型验证：至少两个模型都通过才算通过；两个模型都不通过的品类改用更窄的名称。

代码、AI 原始回答、证据记录和逐类结果都在仓库中：<https://github.com/moyunxiang/ai-observatory>。本文所有数字都可以从已保存的回答重新计算。

附录：逐类结果

#	品类	品牌数 (W/C)	DeepSeek 第 1 轮 补表前 → 补表后	最终	留出	Qwen
1	Smartphones	14 (5/9)	0.7 → 1.0	Pass	0.8	0.9
2	Search Engines	12 (9/3)	1.0 → 1.0	Pass	0.9	0.9
3	Social Media Platforms	17 (10/7)	0.9 → 0.9	Pass	1.0	0.8
4	Short Video Apps	15 (10/5)	0.7 → 0.9	Pass	0.9	1.0
5	Video Streaming Services	16 (11/5)	1.0 → 1.0	Pass	1.0	0.9
6	Music Streaming Services	14 (11/3)	0.6 → 1.0	Pass	1.0	0.9
7	Online Shopping Platforms	16 (9/7)	0.4 → 0.9	Pass	0.8	0.0
8	Fast Food Chains	18 (18/0)	0.7 → 1.0	Pass	1.0	0.9
9	Coffee Chains	17 (15/2)	0.7 → 1.0	Pass	0.9	0.7
10	Bubble Tea Chains	18 (11/7)	0.7 → 0.9	Pass	0.9	0.7
11	Hot Pot Restaurant Chains	13 (0/13)	0.7 → 1.0	Pass	0.7	0.5
12	Soft Drinks	14 (13/1)	0.7 → 1.0	Pass	0.9	0.9
13	Bottled Water	20 (17/3)	0.5 → 0.8	Pass	0.9	0.7
14	Dairy Products	15 (13/2)	0.7 → 0.9	Pass	0.2	0.3
15	Baijiu	17 (0/17)	0.9 → 0.9	Pass	0.9	0.9
16	Beer	23 (17/6)	0.1 → 1.0	Pass	0.6	0.6
17	Energy Drinks	18 (16/2)	0.5 → 0.8	Pass	0.7	0.5
18	Soy Sauce	17 (12/5)	0.6 → 1.0	Pass	0.2	0.9
19	Processed Meat Products	16 (14/2)	0.6 → 1.0	Pass	0.3	0.6
20	Banks	29 (19/10)	1.0 → 1.0	Pass	1.0	0.4
21	Payment Card Networks	11 (10/1)	0.4 → 0.4 (改名后: 0.9 → 0.9)	Pass	0.9	0.9
22	Digital Payment Services	12 (10/2)	0.9 → 0.9	Pass	0.9	0.6
23	Insurance Companies	21 (15/6)	0.8 → 0.8	Pass	0.7	0.4
24	Health Insurance	11 (11/0)	0.8 → 0.8	Pass	0.8	0.8
25	Mobile Carriers	21 (18/3)	1.0 → 1.0	Pass	0.9	0.3
26	Internet Service Providers	12 (12/0)	0.8 → 0.8	Pass	0.9	1.0
27	Airlines	24 (19/5)	0.9 → 0.9	Pass	1.0	0.9
28	Express Delivery Services	17 (10/7)	0.8 → 1.0	Pass	0.7	0.9
29	Food Delivery Platforms	14 (12/2)	0.8 → 0.8	Pass	0.9	0.8

#	品类	品牌数 (W/C)	DeepSeek 第 1 轮 补表前 → 补表后	最终	留出	Qwen
30	Ride-Hailing Apps	10 (9/1)	0.9 → 0.9	Pass	0.9	0.8
31	Online Travel Agencies	17 (13/4)	0.7 → 1.0	Pass	0.9	0.7
32	Hotel Chains	22 (19/3)	0.7 → 1.0	Pass	0.5	0.4
33	Restaurant Review Platforms	12 (11/1)	0.9 → 0.9	Pass	1.0	0.8
34	Real Estate Agencies	15 (13/2)	0.8 → 1.0	Pass	0.9	0.8
35	Chinese Real Estate Developers	12 (0/12)	0.0 → 0.0 (改名后: 0.8 → 0.9)	Pass	0.8	0.7
36	Electric Vehicles	19 (11/8)	1.0 → 1.0	Pass	0.9	0.9
37	Cars	16 (14/2)	0.9 → 0.9	Pass	0.8	0.7
38	Luxury Fashion	17 (17/0)	0.7 → 1.0	Pass	1.0	0.7
39	Sportswear	14 (12/2)	0.6 → 1.0	Pass	0.8	0.8
40	Fast Fashion	13 (12/1)	0.9 → 0.9	Pass	1.0	0.8
41	Cosmetics	18 (17/1)	0.9 → 0.9	Pass	0.5	0.6
42	Jewelry	19 (12/7)	0.4 → 1.0	Pass	1.0	0.8
43	Home Appliances	19 (15/4)	0.6 → 1.0	Pass	0.8	0.7
44	Air Conditioners	13 (10/3)	0.7 → 0.9	Pass	0.7	0.8
45	TVs	10 (7/3)	0.8 → 0.8	Pass	0.9	0.8
46	Laptops	11 (9/2)	0.8 → 0.8	Pass	0.9	0.9
47	Drones	12 (3/9)	0.8 → 0.8	Pass	0.5	0.7
48	Video Game Consoles	16 (14/2)	0.6 → 1.0	Pass	1.0	0.8
49	Consumer Electronics	15 (13/2)	0.6 → 1.0	Pass	0.8	0.7
50	AI Chatbot Apps	15 (11/4)	0.8 → 0.9 (改名后: 0.8 → 1.0)	Pass	0.9	0.5
51	Supermarket Chains	16 (15/1)	0.7 → 0.9	Pass	0.7	0.7
52	Home Improvement Retail Chains	15 (15/0)	0.5 → 0.5 (改名后: 0.8 → 1.0)	Pass	1.0	0.7
53	Furniture Stores	13 (13/0)	0.5 → 0.8	Pass	1.0	0.8
54	Traditional Chinese Medicine	12 (1/11)	0.6 → 0.8	Pass	0.6	0.2
55	Online Healthcare Platforms	18 (13/5)	0.3 → 0.8	Pass	0.6	0.6
56	Job Search Platforms	15 (9/6)	0.8 → 0.8	Pass	0.8	0.9
57	News Apps	17 (14/3)	0.7 → 1.0	Pass	0.9	0.6
58	Video Game Companies	24 (21/3)	0.5 → 1.0	Pass	0.8	1.0
59	Movie Studios	16 (16/0)	0.8 → 0.8	Pass	0.8	0.9
60	Cigarette Brands	14 (14/0)	0.0 → 0.0 (改名后: 0.6 → 1.0)	Pass	0.0	0.9

列定义。品牌数 (W/C)：品牌表行数 (World / China)。DeepSeek 第 1 轮 补表前 → 补表后：第 1 轮的 Recall@10；5 个改名品类在括号中给出第 2 轮结果。最终：最近一次尝试的结果，决定是否进入主表。留出：冻结表后 DeepSeek 在 temperature 1.0 下的结果。Qwen：冻结表后 Qwen 3.7 Plus 的结果。所有 recall 取值 0–1，均为单次采样。